

Laporan Praktikum 2: Praproses Data

Muhammad Farid Wijdan (5054251042) | Dataset House Prices, train.csv


Data awal: 1.460 baris x 81 kolom | Data akhir: 1.460 baris x 173 kolom | Nilai hilang akhir: 0

1. Pemeriksaan dan penanganan nilai hilang

Data diperiksa dengan `head()`, `shape`, `info()`, dan `isna().sum()`. Lima kolom dengan lebih dari 50% nilai kosong dihapus: `PoolQC`, `MiscFeature`, `Alley`, `Fence`, dan `MasVnrType`. Alasannya, pengisian sebagian besar isi kolom akan terlalu banyak bergantung pada perkiraan. Data tersisa 76 kolom.

Pada kolom yang tersisa, 1.550 sel kosong diisi: angka dengan median (tahan terhadap nilai ekstrem) dan kategori dengan modus (nilai yang paling sering muncul). Setelahnya tidak ada nilai hilang.


Keterbatasannya, nilai kosong yang berarti tidak ada fasilitas dapat kehilangan makna.



2. Deteksi dan penanganan outlier

Boxplot digunakan pada empat fitur ukuran. Nilai di luar batas $Q1 - 1,5 \times IQR$ sampai $Q3 + 1,5 \times IQR$ dibatasi ke nilai batas terdekat (capping). Cara ini mengurangi pengaruh nilai ekstrem tanpa menghapus rumah. `SalePrice` tidak diubah karena merupakan target.

Nilai yang disesuaikan: LotArea 69 | GrLivArea 31 | TotalBsmtSF 61 | GarageArea 21



Boxplot sebelum penanganan. Jumlah baris tetap 1.460 setelah outlier dibatasi.

Transformasi dan Dataset Akhir


3. Korelasi, encoding, dan standardisasi

Korelasi absolut antar fitur numerik diperiksa dengan ambang 0,90. Tidak ada pasangan yang melewati batas, jadi tidak ada fitur dibuang. Pasangan tertinggi adalah GarageCars dan GarageArea (0,893). Pemeriksaan ini bertujuan mengurangi informasi yang hampir sama bila ditemukan.

Atribut kategori diubah menjadi kolom 0/1 dengan one-hot encoding agar dapat dihitung tanpa membuat urutan kategori yang palsu. Hasilnya 271 fitur. Semua fitur kemudian distandardisasi memakai z-score agar skala luas rumah dan kolom kategori setara sebelum PCA. Id dan SalePrice tidak dimasukkan sebagai fitur.

4. Reduksi dimensi dengan PCA

PCA diterapkan pada 271 fitur hasil standardisasi dengan SVD dari NumPy. Dipilih jumlah komponen terkecil yang mencakup sedikitnya 95% variasi data. Hasilnya 171 komponen menjelaskan 95,15% variasi; jumlah fitur berkurang 100 kolom (36,9%).



PCA meringkas fitur, tetapi tiap komponen baru tidak mudah ditafsirkan sebagai atribut rumah tertentu.

5. Ringkasan dataset akhir

CSV akhir berisi Id, PC1-PC171, dan SalePrice: 1.460 baris x 173 kolom tanpa nilai hilang. Id hanya penanda baris; SalePrice tetap pada nilai aslinya. Semua baris data awal dipertahankan. Dataset dapat digunakan untuk analisis atau tahap pemodelan berikutnya.

Jika nanti data dipisah menjadi data latih dan uji, median, modus, standardisasi, dan PCA perlu dihitung dari data latih saja agar tidak terjadi kebocoran informasi.

Sumber: Kaggle, House Prices - Advanced Regression Techniques, train.csv.

<https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques/data>