Laporan Praktikum 3: Ensemble Method & Class Imbalance

Klasifikasi transaksi kartu kredit berpotensi fraud

Muhammad Farid Wijdan — 5054251042

1. Tujuan dan dataset

Praktikum ini membandingkan Random Forest tanpa penanganan imbalance, Random Forest dengan class_weight=balanced_subsample, dan SMOTE + Random Forest. Dataset Credit Card Fraud Detection berisi 284.807 transaksi dan 30 fitur numerik (Time, Amount, V1–V28); target Class bernilai 1 untuk fraud. Ada 492 transaksi fraud (0,1727%) dan 284.315 transaksi normal. Data diunduh dari salinan dataset Kaggle yang diarsipkan di Zenodo; dataset tidak dimasukkan ke repo karena ukurannya sekitar 150,8 MB.

2. Metode

Data dibagi sekali dengan train_test_split(test_size=0.20, random_state=42, stratify=y): 227.845 baris training dan 56.962 baris testing. Set uji berisi 98 fraud dan tetap pada distribusi alami. Semua model menggunakan 100 pohon Random Forest, seed 42, dan seluruh inti CPU. Untuk eksperimen SMOTE, oversampling berada di imbalanced-learn Pipeline sehingga hanya diterapkan saat fitting data training. Evaluasi menggunakan precision, recall, F1-score, ROC-AUC, average precision (PR-AUC), serta confusion matrix.

3. Hasil evaluasi pada test set

Model	Precision	Recall	F1	ROC-AUC	PR-AUC	TN / FP / FN / TP
RF baseline	0,9412	0,8163	0,8743	0,9630	0,8734	56859 / 5 / 18 / 80
RF class_weight	0,9600	0,7347	0,8324	0,9529	0,8597	56861 / 3 / 26 / 72
SMOTE + RF	0,8351	0,8265	0,8308	0,9644	0,8747	56848 / 16 / 17 / 81

4. Analisis

RF baseline memperoleh F1 dan precision tertinggi pada threshold default, menangkap 80 dari 98 fraud dengan 5 false positive. Class weighting menghasilkan precision tertinggi (0,9600) dan false positive paling sedikit (3), namun recall turun menjadi 0,7347 sehingga 26 fraud terlewat. SMOTE mencapai recall tertinggi (0,8265) dan PR-AUC tertinggi (0,8747), menangkap 81 fraud, tetapi false positive meningkat menjadi 16 dan precision turun menjadi 0,8351. Perbedaan menunjukkan trade-off: weighting lebih konservatif, sedangkan SMOTE menangkap sedikit lebih banyak fraud dengan lebih banyak alarm palsu. Model baseline pada split ini memberi F1 terbaik (0,8743).

Accuracy tidak digunakan sebagai ukuran utama karena 99,827% data adalah transaksi normal. Prediksi semua transaksi sebagai normal saja sudah menghasilkan accuracy sangat tinggi, tetapi recall fraud menjadi nol. PR-AUC lebih informatif pada kelas positif langka; ROC-AUC tetap dicantumkan agar perbandingan diskriminasi umum tersedia.

5. Kesimpulan dan batasan

Pada satu split stratified, Random Forest baseline memberi keseimbangan precision-recall terbaik menurut F1. SMOTE memberi recall dan PR-AUC terbaik, sedangkan class weighting menekan false positive. Keputusan model yang tepat harus mempertimbangkan biaya FN vs FP dan threshold operasional, bukan memilih teknik hanya dari satu metrik. Hasil ini bukan validasi produksi: belum dilakukan cross-validation, tuning hyperparameter/threshold, analisis biaya, atau uji temporal. Dataset berisi fitur PCA anonim sehingga interpretasi fitur terbatas.

Reproduksi: jalankan notebook di folder ini setelah meletakkan creditcard.csv di folder yang sama. Hasil numerik laporan dihasilkan dari file dataset lengkap, stratified split random_state=42, dan tiga model Random Forest 100 trees. Sumber: Kaggle MLG-ULB (https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud); arsip data: https://zenodo.org/records/7395559.