

Laporan Praktikum 1: Scraping & Eksplorasi Data (EDA)

Muhammad Farid Wijdan 5054251042

Deskripsi Dataset

Dataset diperoleh melalui scraping halaman MyAnimeList Top Manga menggunakan requests dan BeautifulSoup. Pengambilan dilakukan terhadap 30 halaman dengan masing-masing 50 entri, sehingga diperoleh **1.500 baris data**. Hasil scraping mentah disimpan terlebih dahulu sebagai `mal_topmanga_raw.csv` agar proses scraping tidak perlu diulang.

Dataset awal memiliki 12 atribut, yaitu `rank`, `manga_id`, `title`, `url`, `type`, `volumes`, `date_text`, `start_text`, `end_text`, `start_year`, `members`, dan `score`. Satu atribut tambahan, `status`, dibuat dari `end_text`: data dengan `end_text` kosong diberi status **Ongoing**, sedangkan yang memiliki tanggal selesai diberi status **Finished**.

Klasifikasi tipe atribut yang digunakan pada notebook adalah:

Tipe atribut	Atribut
Nominal	<code>title</code> , <code>url</code> , <code>type</code> , <code>date_text</code> , <code>start_text</code> , <code>end_text</code>
Ordinal	<code>status</code> (Ongoing < Finished)
Numerik diskrit	<code>rank</code> , <code>manga_id</code> , <code>volumes</code> , <code>start_year</code> , <code>members</code>
Numerik kontinu	<code>score</code>

Statistik Deskriptif

Statistik menunjukkan bahwa nilai `score` relatif terkonsentrasi, sedangkan `members` memiliki sebaran yang jauh lebih lebar. Rata-rata `members` sebesar 40.355 jauh di atas mediannya yang hanya 16.286, yang mengindikasikan adanya beberapa judul dengan popularitas sangat tinggi.

Atribut	Count	Mean	Median	Std	Min	Max
<code>score</code>	1500	8,129	8,060	0,282	7,80	9,46
<code>members</code>	1500	40.355	16.286	76.579	464	808.729
<code>volumes</code>	1040	11,917	9	11,018	1	78
<code>start_year</code>	1499	2010,77	2012	9,75	1966	2026

Untuk atribut kategorikal, tipe **Manga** mendominasi dengan 1.029 judul, diikuti **Light Novel** 203, **Manhwa** 200, **Novel** 39, **Manhua** 19, dan **One-shot** 10. Berdasarkan atribut turunan `status`, terdapat 1.114 judul **Finished** dan 386 judul **Ongoing**.

Kualitas dan Penanganan Data

Nilai hilang ditemukan terutama pada `volumes` sebanyak 460 data (30,67%), `end_text` sebanyak 386 data (25,73%), dan `start_year` sebanyak 1 data (0,07%). Missing value pada `end_text` berkaitan langsung dengan judul yang masih **Ongoing**, sedangkan `volumes` yang kosong berasal dari entri yang tidak mencantumkan jumlah volume secara pasti. Karena kondisi tersebut memiliki makna pada data dan bukan sekadar kesalahan pembacaan, nilai-nilai tersebut dibiarkan apa adanya.

Deteksi outlier menggunakan metode IQR menghasilkan 37 outlier pada `score`, 177 pada `members`, dan 28 pada `volumes`. Batas IQR yang diperoleh berturut-turut adalah 7,33–8,85 untuk `score`, –38.217,75–82.888,25 untuk `members`, dan –18–38 untuk `volumes`. Outlier tidak dihapus karena nilai ekstrem tersebut masih merepresentasikan kondisi nyata, misalnya judul yang sangat populer atau memiliki jumlah volume jauh lebih banyak daripada mayoritas data.

Visualisasi dan Interpretasi




Figure 1: Histogram distribusi score dan members.

Sebagian besar score terkumpul pada kisaran sekitar 7,9–8,3. Sebaliknya, distribusi members sangat miring ke kanan: mayoritas judul memiliki jumlah anggota relatif kecil dan hanya sedikit judul yang memiliki anggota hingga ratusan ribu.




Figure 2: Jumlah judul berdasarkan type.




Figure 3: members terhadap score.




Figure 4: Heatmap korelasi atribut numerik.




Figure 5: Distribusi score pada setiap type.

Bar chart menegaskan bahwa tipe **Manga** jauh lebih dominan dibanding tipe lain. Scatter plot menunjukkan hubungan positif sedang antara members dan score, dengan koefisien korelasi sekitar **0,421**. Artinya, judul yang lebih populer cenderung memiliki skor lebih tinggi, tetapi hubungan tersebut tidak mutlak karena tetap terdapat judul dengan members rendah namun score tinggi.

Pada heatmap, hubungan paling kuat terlihat antara rank dan score dalam arah negatif. Hal ini sesuai dengan mekanisme ranking: semakin tinggi skor, semakin kecil nomor rank. Sementara itu, korelasi antaratribut numerik lainnya relatif lebih lemah. Boxplot juga memperlihatkan median score antar tipe yang hampir serupa, sehingga tipe publikasi tidak terlihat sebagai pembeda utama skor dalam dataset ini.

Kesimpulan

Hasil EDA menunjukkan bahwa dataset Top Manga MyAnimeList didominasi oleh tipe **Manga** dan judul berstatus **Finished**. Distribusi score cukup rapat di sekitar nilai 8, sedangkan popularitas berdasarkan members sangat tidak merata. Missing value dan outlier yang ditemukan tidak langsung dihapus karena sebagian besar memiliki penjelasan yang sesuai dengan karakteristik data. Selain itu, popularitas dan skor memiliki hubungan positif sedang, tetapi popularitas tidak dapat dianggap sama dengan kualitas karena banyak judul dengan jumlah anggota lebih kecil tetap memperoleh skor tinggi.